

ФАЛЬКОН **tex**



ПРОЕКТ
МЭРА
МОСКВЫ

БИЗНЕС
МОСКВЫ



РАЗВИТИЕ
ЧЕЛОВЕЧЕСКОГО
КАПИТАЛА



ЛИДЕРЫ
ЦИФРОВОЙ
ТРАНСФОРМАЦИИ

Цифровой признак автомобиля без госномера

Команда znatalk.ai • ЛЦТ 2026, кейс Фалькон Тех



О команде

- **Капитан:** Дворядкин Кирилл, тимлид
- **Кол-во участников:** 3 человека
- **Краткое описание:**
 - друзья и коллеги, вместе зарегистрировались на хакатон;
 - работа/учёба: Госинспекция по недвижимости, НИТУ МИСИС
- **Город и регион:** Москва

КОМАНДА «ZNATALK.AI»

Краткое описание решения:

Находим тот же автомобиль на снимках разных камер только по внешнему виду: оператор выделяет машину на кадре и получает топ-10 кандидатов или обоснованный отказ.

Уникальность решения:

DINOv3 ViT-L/16, дообученный на 416 тыс. публичных снимков и данных конкурса; откалиброванный отказ; одна ONNX-модель в контуре жюри и в сервисе на Rust + pgvector.

КОМАНДА



**Кирилл
Дворядкин**

- Капитан, тимлид
- @KD_ATW
- +7 920 544-59-01
- Госинспекция по недвижимости



**Сергей
Глухов**

- ML-инженер
- @sglukhovcom
- +7 968 573-05-21
- Госинспекция по недвижимости



**Иван
Вологин**

- Бэкенд-разработчик
- @servan_t
- +7 985 436-35-61
- НИТУ МИСИС

Краткая история команды:

01

Друллеги, вместе работали в Госинспекции по недвижимости, вместе учились. Зарегистрировались и сразу поделили зоны: ML, нативный бэкенд, инфраструктура и интерфейс.

Почему вы выбрали именно эту задачу из предложенных на хакатоне?

02

Прикладной городской сценарий, где номер часто не виден, и честная метрика: хотелось сделать не только модель, но и рабочий сервис для оператора.

С какими основными сложностями или вызовами вы столкнулись и как их преодолели?

03

Zero-shot модели узнавали камеры, а не машину, и мы перешли к метрическому обучению с выборкой по камерам. Перед и зад, одинаковые машины каршеринга и ночь остаются главными ошибками.

Бюджет ≤ 40 мс на GPU уложили через ONNX FP16 и ускоренный препроцессинг; честность оценки - раздельными фолдами для отбора модели, порога и аудита.

КОРОТКО О РЕШЕНИИ



Техническая суть решения

- DINOv3 ViT-L/16 + BN-neck → вектор 1 024, L2-норма; вход только кроп по bbox.
- Обучение: VERI-Wild (416 314 снимков, 40 671 TC) → данные конкурса, выборка 2+2 по камерам, triplet + CE.
- Поиск: косинус + DBA по галерее; отказ, если топ-1 ниже порога 0,7207.
- SEARCH mAP@10 92,00 %, аудит 87,00 %; 22–25 мс и 180+ FPS на RTX 3090.
- Rust-сервисы (gRPC), PostgreSQL + pgvector, React, OpenAPI, Docker Compose.

Маркетинговая суть решения

- Оператор получает топ-10 кандидатов с оценкой близости вместо ручного просмотра архива камер.
- Работает, когда номер нечитаем: грязь, блики, ракурс, перекрытие.
- Отказ при слабом совпадении снижает ложные срабатывания.
- Развитие: связка с событиями, где номер известен; потоковая обработка камер; дообучение на подтвержденных оператором парах.

Почему DINOv3 ViT-L/16

- Zero-shot энкодеры различали камеру, а не машину: CLIP ViT-B/16 лишь 0,137 mAP@10. Нужна метрическая доводка.
- DINOv3 самообучаемый foundation-энкодер с сильными мелкозернистыми признаками: детали кузова, диски, наклейки.
- ViT-L/16 при 256×256 укладывается в бюджет жюри: 22–25 мс на кадр, 607 МБ при лимите 2 ГБ.
- Номер, OCR, камера и время в модель не поступают.

Ракурс и освещение

- Предобучение на VERI-Wild: 416 314 снимков, 40 671 ТС, разное время суток и погода.
- Выборка 2+2: у каждой машины в батче кадры с двух разных камер, модель сводит ракурсы.
- Batch-hard triplet + CE со сглаживанием меток, BN-neck.
- DBA по галерее ($k=4$, $\alpha=2$) сглаживает её по соседям; запросы независимы.
- Контроль: маска зоны номера снижает SEARCH лишь на 0,71 п.п.

01

Разделение ролей данных

- 9 556 размеченных снимков конкурса; 1 860 входных снимков жюри.
- FIT, SEARCH, калибровка и аудит не пересекаются по машинам и сценам.
- Снимков жюри в обучении нет. Проверка хешей и декодированных пикселей: пересечений между ролями нет.

02

Внешнее обучение

- Публичный VERI-Wild TRAIN + TEST: 416 314 снимков, 40 671 ТС. Обучение на внешнем test было разрешено.
- Каждый файл перехеширован: точных пересечений с конкурсом нет.
- Ревизия foundation-модели и лицензии зафиксированы.

03

Дообучение на конкурсе

- Замороженный прогон FIT-v8: 5 722 кропа, 928 ТС, 8 эпох.
- Метрическое обучение: triplet + BN-neck. Рецепт и снимки исходников сохранены.
- 24 исторических исключения FIT раскрыты. Новых чисток и переразметки нет.

04

Замороженная оценка

- SEARCH выбирал модель. Калибровка выбирала пороги отказа.
- Аудит ранее открывался для прошлой модели: не выдаём его за нетронутый тест.
- Модель и пороги заморожены до новой калибровки и аудита.



1. Кадр и рамка

Оператор загружает кадр и выделяет машину в браузере.

API валидирует запрос. Энкодер строит нормированный вектор внешнего вида по кропу.

2. Поиск по галерее

Сервис ищет в pgvector HNSW по текущей версии модели.

Возвращает до 10 кандидатов с оценкой близости. Порог косинуса в сервисе = 0,695986.

3. Проверка или отказ

Оператор сравнивает кропы и детали кандидатов. Слабое совпадение — отказ.

Экспорт CSV и управление галереями в интерфейсе и через REST API.

01

Вход: веб и шлюз

- React-интерфейс в браузере и REST / OpenAPI.
- Валидация запросов и gRPC-маршрутизация к сервисам-владельцам.

02

Модель: инференс

- Кроп, RGB-препроцессинг и замороженный ONNX-энкодер.
- Запросы обрабатываются без состояния, без адаптации между запросами.
- В образе жюри обязателен GPU.

03


Хранение и поиск

- Gallery владеет снимками и метаданными.
- Search читает эмбединги и хранит историю поиска.
- PostgreSQL 16 + pgvector HNSW: реляционное и векторное хранилище.
- Tagger, необязательный сервис пояснений.

КАЧЕСТВО ПОИСКА



mAP@10 по ролям оценки, %



SEARCH (отбор): 92,005 %

172 оцениваемых запроса. Исходный чекпойнт TT 91,956 % в BF16. Повторное 8-эпохное обучение FIT 91,213 %. SEARCH - данные разработки.

Финальный аудит: 87,003 %

160 запросов; 95 % бутстрэп-интервал по машинам 82,32-91,14 %. Этот фолд ранее открывался для прошлой модели.

Калибровка: 83,000 %

160 известных + 40 неизвестных запросов. Модель уже выбрана; калибруются только пороги отказа.

$$0,7 \cdot F1 + 0,3 \cdot TNR$$

Целевая функция отказа

Порог DBA: 0,720701

Калибровка: Q 0,9583

Аудит: Q 0,9365

Финальная модель, Linux, CUDA

Принимаем топ-1, только если его оценка не ниже порога. Иначе запрос не попадает в файл кандидатов.

В калибровке 160 известных и 40 неизвестных запросов: доля «нет в галерее» 20 %.

Калибровка: TP 142, FP 0, FN 18, TN 40. F1 0,9404, TNR 1,0000.

Финальный аудит: TP 141, FP 2, FN 19, TN 38. F1 0,9307, TNR 0,9500.

Порог живого сервиса (чистый косинус) отдельный: 0,695986. Q на аудите ниже прошлой модели (0,9581), mAP — выше.

Препроцессинг на CPU, медиана, мс



Что меряет жюри

Полная задержка `extract()`: чтение файла, декодирование, кроп, препроцессинг, `forward` и L2-нормировка. Целевое железо: RTX A5000.

Пороги оценки

Полный балл: `batch-1` не дольше 40 мс и не менее 100 FPS.
Модель 607,3 МБ при лимите 2 ГБ.

Локальные замеры


RTX 3090: нативный путь 22,42–24,58 мс (медиана) / 181,5–185,9 FPS; Python 24,99–27,65 мс / 110,5–119,0 FPS. Повторные выходы совпадают побайтно. RTX JIT выключен. A5000 / драйвер 535 не проверены.

АНАЛИЗ ОШИБОК

Запрос и верные виды спереди (зелёные рамки)



Чужая машина, похожий вид сзади



Только пример разработки. У публичного теста нет разметки.

Перед против зада

SEARCH, машина 1258: после удаления кадров той же камеры первый верный вид спереди на 9-м месте; в топ-10 попал один из двух верных видов.

Почти одинаковые машины

Похожий G-класс сзади - размеченный пример разработки. Высокое сходство внешнего вида ещё не означает ту же машину.

Перекрытия и освещение

Разбор также выявил смешанные рамки, частично видимые машины и пары «ночь/день». Разметку не меняли.

Контроль маскирования номера

SEARCH mAP: 92,005 % исходно, 91,292 % с зачернённой зоной номера, 91,802 % со случайными масками той же площади. Это не точный тест масок жюри.

ПЛАН МАСШТАБИРОВАНИЯ



Приём

План: очередь событий и асинхронные воркеры сглаживают пики от множества камер, с повторами и ограниченным бэклогом.

1

2

3

4

5

Инференс

План: несколько GPU-реплик и динамический батчинг с мониторингом задержки и загрузки.

Векторный индекс


Проведённый синтетический тест на 1 млн векторов: HNSW p50 33 мс, p95 60 мс, recall@10 0,79. Перепроверить на 1 024 измерениях.

Хранение снимков

План: объектное хранилище с политиками хранения. PostgreSQL: события, идентичности, права и журнал аудита.


Обновление модели

План: версии моделей, проверенная обратная связь операторов, отдельные данные для перекалибровки и откат после проверки дрейфа.



• Интерфейс поиска

- Скриншот прототипа: выбор машины на кадре, список кандидатов, отказ и экспорт CSV. Стенд: <https://lct.znataalk.ai>.



• Сравнение деталей

- Скриншот прототипа: визуальные области помогают оператору сверить кандидата. OpenAPI /api/docs, готовность - /api/health и /api/info.

ИТОГИ И ССЫЛКИ

Сдано: исходный код, закреплённая модель и манифест, офлайн-образ с CUDA, три файла предсказаний, рецепт обучения и доказательная база.

Проверено локально: пересобранный образ, Python и нативный GPU-путь, повторяемость, независимость запросов, отсутствие точных пересечений входов.

Ссылки: репозиторий gitlab.com/kadvoryadkin/lct-2026, демо lct.znataik.ai, пояснительная записка [docs/Пояснительная_записка.pdf](#).

SEARCH 92,005 %